

# Õpiraja hindamiskomponent

## Teadmusruumi adaptiivse testi simulatsioonid

Aivar Ots 07.08.26

Lihtne lineaarne KST mudel<sup>1</sup> kajastab sisult Guttmani skaalat, kus täielik kompetentsus saavutatakse õppimisel kindlas järjekorras uusi teadmisi-oskusi omandades. Testimisel – ja eriti adaptiivsel testimisel, tähendab see tundlikkust nii algse mudeli kehtivuse (nt kas õpidisainer on protsessi käigu adekvaatselt määratlenud) kui testimise jooksul vastaja adekvaatsuse ja järjepidevuse suhtes (st iga vastus kajastab üheselt vastaja tõest teadmist või -teadmatust)<sup>2</sup>.

Probleem testimisel tekib olukorras, kus adaptiivne algoritm ei suuda piisava kindlusega vastaja asukohta võimalike profiilide hulgas tuvastada ning püüab anda vastajale üha uusi ülesandeid. Test muutub pikemaks, vajalik on suurem arv valmis pandud ülesandeid. Teenuse ülesehituse ja jõudluse tagamiseks on vaja teada, kui suureks kujunevad erinevates tingimustes usaldusväärseid tulemusi andvad testid. Samuti kas/kuidas tekivad marginaalsed olukorrad, kus algoritm ei saa vastaja seisundit hinnata.

Järgnevas uurime:

- (1) Kuidas mõjutab ilma pikkuse piiranguteta testi (pole minimaalse või maksimaalse ülesannete arvu nõudeid) pikkust kasutaja vastuste adekvaatsus erineva sõlmede hulga teadmiseruumi korral?
- (2) Kuidas vastuste adekvaatsus mõjutab eri mahuga teadmiseruumi testide tulemuse kehtivust (kui sageli tuvastatakse vastaja tõene teadmisseisund)?
- (3) Kui suurel arvul ülesandeid kasutatakse üldiselt ühes testis ühe sõlme kohta?

Läbivalt on kasutatud lineaarse ülesehitusega teadmiseruumi, kus kõik sõlmed moodustavad eeldustena ühe ahela. Kasutatud on 4, 8 ja 16 sõlmelise teadmiseruumiga teste. Testi algseks stopp-reegliks on ühe teadmisseisundi vähemalt 80% tõenäosusega esinemise saavutamine.

Esmalt on vaadeldud eri sõlmede arvuga testide pikkusi olukorras, kus testi pikkusele nõuded puuduvad, testimine peatub 80% tõenäosuse saavutamisel ühe teadmisseisundi (profiili) puhul. Kasutatud on kolme vastaja profiili, mis erinevad selle poolest kui adekvaatselt vastused kajastavad vastaja tõest seisundit: (1) hoolikas –  $\beta = 0,02$ ,  $\eta = 0,10^3$ , (2) hooletu –  $\beta = 0,25$ ,  $\eta = 0,10$  ja (3) õnnelik –  $\beta = 0,05$ ,  $\eta = 0,40$ .




---

<sup>1</sup> Vt lähemalt: Falmagne, J.-C., Koppen, M., Villano, M., Doignon, J.-P., & Johannesen, L. (1990). Introduction to knowledge spaces: How to build, test, and search them. *Psychological Review*, 97(2), 201–224.  
<https://doi.org/10.1037/0033-295X.97.2.201>

<sup>2</sup> Lisaks on mõju ka sõlmede kohta koostatud ülesannete kvaliteedil, mida käsitleme hilisemas etapis juba kogutud empiiriliste andmete abil.

<sup>3</sup>  $\beta$  – tõenäosus, et vastaja eksib tasemel, mida valdab,  $\eta$  – tõenäosus, et vastaja annab õige vastuse ülesandes, mis ületab tema teadmisseisundit.

*Ilma pikkuse piiranguteta testi peatumiseks vajalike ülesannete hulk (reegel – parim posteriori  $p > 0,8$ )*



- Ilma testi pikkuse reguleerimiseta olukorras kulub väiksema sõlmede arvuga testis vähem ülesandeid ja pikemas testis rohkem.
- Teadmise/mitte teadmise adekvaatne kajastus vastustes võimaldab vastaja taseme rutem tuvastada (test on lühem).

### *Kalibreeritus: kui hästi suudab test leida vastaja tõese seisundi?*

Hindamisel üldiselt – aga eriti reaalas loodava testi ja tulemuste tagasisidestamisel – on keskne küsimus, **kui täpselt suudetakse vastaja seisund tuvastada**. Kui parameetrilisel sooritusvõime hindamisel keskendutakse hinnangu vea ulatusele (nt testi punktide vahemik, kuhu vastaja n-ö tõene skoor peaks jääma 95% tõenäosuse juures), siis KST meetodi puhul saab küsida kui sageli õnnestub määrata vastaja tõene teadmisseisund.

KST algoritm arvestab, et valikvastustega ülesandele vastatakse kogemata õigesti (ebakompetentne inimene annab õige vastuse). Samuti läheb arvesse ka võimalus, et kogemata vastatakse valesti (kompetentne inimene annab vale vastuse). Need on ülesande mõõtmisomadused, mida arvestatakse teadmisseisundi esinemise tõenäosuse leidmisel. Samas vastajad võivad personaalselt erineda nii kogemata valesti vastamise (n-ö hooletu vastamine) kui ka juhuslike õigete vastuste osas (õnn vastamisel).

Õppimise käigus jooksva hindamisel oleme lisaks seotud kasutajale vastuvõetava hindamise mahuga (palju aega ja energiat tagasiside saamiseks tuleb tal kulutada) ning probleemiga, kuidas määrata hetk testi katkestamiseks, kui algoritm ei suuda usaldusväärse hinanguni jõuda.

Seda, kui hästi on KST mudel kalibreeritud – ehk kui täpselt suudab see tuvastada vastaja tõese seisundi, uuriti lihtsa simulatsiooniga, kus kasutati kolme vastaja profiili: (1) hoolikas –  $\beta = 0,02$ ,  $\eta = 0,10^4$ , (2) hooletu –  $\beta = 0,25$ ,  $\eta = 0,10$  ja (3) õnnelik –  $\beta = 0,05$ ,  $\eta = 0,40$ . simulatsioonis sai seadistada teadmiseruumi sõlmede arvu, seisundi tuvastamiselt nõutud tõenäosuse taset, minimaalselt nõutud ja maksimaalselt lubatud testi pikkust.

- KST suudab adekvaatselt õigesti/valesti vastava kasutaja seisundi leida suure täpsusega (~97% klassifikatsioone on õiged)
- Ebaühtlasemalt vastuseid andva isiku seisundit aga piisavalt hästi ei tuvastata. Ainult ca pooled klassifikatsioonid on kehtivad.

**Tabel 1.** Ülesannete arv ja õige seisundi tuvastamine eri mahuga mudelites (iter. 1200). Vastaja profiil: **hoolikas**

| Näitaja            | 4 sõlme      | 8 sõlme      | 16 sõlme     |
|--------------------|--------------|--------------|--------------|
| M                  | 4,35         | 5,61         | 6,8          |
| MD                 | 4            | 5            | 6            |
| SD                 | 0,89         | 1,37         | 1,66         |
| Leiti õige seisund | <b>97,5%</b> | <b>97,6%</b> | <b>98,0%</b> |
| Vigu*              | 0            | 0            | 0            |

Märkused. \* Jälgiti, kas esineb tulemuste analüüsi katkemist programmist tuleneva tõrke tõttu.

<sup>4</sup>  $\beta$  – tõenäosus, et vastaja eksib tasemel, mida valdab,  $\eta$  – tõenäosus, et vastaja annab õige vastuse ülesandes, mis ületab tema teadmisseisundi.

**Tabel 2.** Ülesannete arv ja õige seisundi tuvastamine eri mahuga mudelites (iter. 1200). Vastaja profiil: *hooletu*

| Näitaja            | 4 sõlme      | 8 sõlme      | 16 sõlme     |
|--------------------|--------------|--------------|--------------|
| M                  | 5,24         | 6,88         | 9,1          |
| MD                 | 4            | 6            | 8            |
| SD                 | 2,12         | 2,68         | 3,43         |
| Leiti õige seisund | <b>55,0%</b> | <b>56,8%</b> | <b>45,5%</b> |
| Vigu               | 0            | 0            | 0            |

**Tabel 3.** Ülesannete arv ja õige seisundi tuvastamine eri mahuga mudelites (iter. 1200). Vastaja profiil: *õnnelik*

| Näitaja            | 4 sõlme      | 8 sõlme      | 16 sõlme     |
|--------------------|--------------|--------------|--------------|
| M                  | 5,1          | 7,06         | 9,31         |
| MD                 | 4            | 6            | 8            |
| SD                 | 1,88         | 2,58         | 3,73         |
| Leiti õige seisund | <b>79,0%</b> | <b>72,2%</b> | <b>71,8%</b> |
| Vigu               | 0            | 0            | 0            |

Simulatsioonis ilma mahu piiranguteta testimisel piisava tõenäosusega ( $p > 0,8$ ) seisundi leidmine on adekvaatsel vastamisel saavutatav üsna väikese arvu valikvastustega ülesannetega (16-sõlmelise teadmusruumi puhul kuni 11-ülesandeliste testidega kaetakse ~98% juhtumitest, tabel 1), saavutades tõese seisundi saavutamise ~98% juhtudest (vale seisund määratakse ca 1 korral 50st).

Samas vastamise ebaadekvaatsuse korral (profiilid *hooletu* ja *õnnelik*) tõenäosuse ländi ületamiseks vajalik ülesannete hulk kasvas ning õigete seisundi klassifikatsioonide osakaal langes isegi alla 50% (16 sõlmeline mudel, profiil *hooletu*, tabel 2).

Manipuleerida saab adaptiivse KST läbiviimist (vt ka ülal simulatsiooni seadistused):

- testi pikkusega
  - minimaalne ülesannete arv, et paar üksikut järjestikust ebaadekvaatset signaali ei tingi kiiret eksliku seisundi kinnitust, paraneb ka sõlmede *esindatus* mõõtmisel;
  - maksimaalne ülesannete arv, et kõrge ebaadekvaatsuse, kus kindla seisundi tuvastamine on takistatud, ei veniks testimise protseduur asjatult pikaks ning ülesannete panga ressursid ei ammenduks (võib tingida nt samade ülesannete kordamist).
- tõenäosuse kriteeriumiga teadmisseisundi kinnitamiseks.

Korrates simulatsiooni 8sõlmelise teadmusruumiga profiilile *õnnelik*, kasutades ländit 0,9, testi minimaalset pikkust 7 ülesannet koos testimise katkestamisega pärast 16 ülesannet saadi testi keskmiseks pikkuseks 12,87 ülesannet koos 87,9% juhtudest õige seisundi

tuvastamisega. Tõstes tõenäosuse kriteeriumi 0,95-ni ning loobudes maksimaalse pikkuse kriteeriumist kasvas keskmine pikkus 13,98 ülesandeni ning õige seisund tuvastati 91% juhtudest. Maksimaalne kasutatud ülesannete arv oli 24.

**Tabel 4.** 8sõlmelise teadmusruumiga simulatsioonid, tõstes seisundi tõenäosuse kriteeriumi ja seades nõuded ülesannete arvule (iter. 7200). Vastaja profiil: õnnelik

| Näitaja            | P = 0,9, Min = 7, Max = 16 | P = 0,95 Min = 7 Max = - |
|--------------------|----------------------------|--------------------------|
| M                  | 12.87                      | 13.98                    |
| MD                 | 12                         | 12                       |
| SD                 | 1.47                       | 3.25                     |
| Leiti õige seisund | 87.9%                      | 91.0%                    |
| Vigu*              | 0                          | 0                        |

Lisades vaatlusi (ülesanded) ja tõstes nõudlikkust tulemuse kehtivusele saab õige seisundi tuvastamist parandada.

Väga oluline on see, et KST paistab olevat tundlik *kogemata valesti vastamise* suhtes (vt tabel 2). Kui profiili *õnnelik* puhul vaatluste arv ja kõrgem kriteerium kompenseerivad võrdlemisi hästi vastaja tõese seisundi suhtes ebaadekvaatset sisendit, siis hooletuse puhul see nii ei ole. Sagedasemad viited madalama teadmisseisundile (ei oska lahendada ülesannet) näivad tugevalt häirivat teadmusseisundi leidmist (ca 75% õigete klassifikatsioonide tasemele õnnestus tingimuste modifitseerimisega jõuda veel kui vastaja profiili beeta väärtus jäi 0,2 tasemele).

*Lihtne simulatsioon on praegu oluline sisend kasutajakogemuse uurimiseks. Omades esmast ettekujutust testimise täpsusest saab paremini tõlgendada nt kasutajate tolerantsust testi pikkuse ja hindamisvea suhtes. Praeguste simulatsiooni näidete puhul on huvitav, et KST puhul tundub olevat keerulisem juhuslikult näida kompetentsem kui Sa tegelikult oled – sagedamini tõene tase peilitakse välja. Samas olukordades, kus kasutaja sageli näib ebaõnnestuvat enda kompetentsuse tasemel, kasvab valeklassifikatsioonide osakaal kiirelt.*

*Sõlmede kaasamine ühel testimisel eri mahuga mudelite korral*

- Üldiselt on ka pikemates **testides 3 ülesande varu sõlme kohta piisav**. Siiski on olukordi, kus üht sõlme on vaja rohkem testida ning ülesandeid on panka juurde vaja. Arvestades simulatsioonis eisenud hajuvust **võiks 5 ülesannet/sõlm anda piisava kindluse, et ühte testi sama ülesande kutsumine on väga haruldane** (aga ei ole välistatud!).
- Suurem ülesannete kasutamine koondub tõese seisundi piirkonda
- Seades nõudeid, mis pikendavad testi (miinimumpikkus, seisundi tõenäosuse tase) ebaadekvaatse vastamise mõju kompenseerimiseks, kasvab ka sõlme kohta keskmiselt vajalike ülesannete hulk. Eeltoodud näidetes (vt tabel 4) **vajati õige seisundi tuvastamiseks kriitilise sõlme kohta juba keskmiselt 5-6 ülesannet ehk ca 2 korda rohkem**.

**Tabel 5.** Keskmine ülesannete arv sõlme kohta erineva pikkusega testides.

| Sõlm | Sõlme kohta kasutatud<br>keskmine ülesannete arv |         |          |
|------|--------------------------------------------------|---------|----------|
|      | 16 sõlme                                         | 8 sõlme | 4. sõlme |
| S1   | 0                                                | 0       | 0,06     |
| S2   | 0                                                | 0,04    | 2,92     |
| S3   | 0,02                                             | 0,63    | 1,24     |
| S4   | 0,04                                             | 2,56    | 0,12     |
| S5   | 0,52                                             | 1,72    |          |
| S6   | 0,58                                             | 0,61    |          |
| S7   | 0,57                                             | 0,05    |          |
| S8   | 2,59                                             | 0       |          |
| S9   | 1,66                                             |         |          |
| S10  | 0,1                                              |         |          |
| S11  | 0,58                                             |         |          |
| S12  | 0,06                                             |         |          |
| S13  | 0,06                                             |         |          |
| S14  | 0,01                                             |         |          |
| S15  | 0,01                                             |         |          |
| S16  | 0                                                |         |          |